

Manual Técnico de Operações e Arquitetura de Software

Organização: Equipe Predicta

Classificação: Confidencial - Nível Industrial

Projeto: Monitoramento Preditivo de Ativos Industriais com IA Generativa

Data: Maio de 2026

1. Visão Geral do Sistema Predicta

O sistema Predicta foi desenvolvido para revolucionar o diagnóstico automatizado de motores elétricos industriais. A arquitetura central utiliza um pipeline RAG (Retrieval-Augmented Generation) integrado a um back-end FastAPI de alta performance. O sistema processa dados de telemetria em tempo real e utiliza recuperação semântica avançada via banco de dados vetorial Qdrant para cruzar métricas atuais com o histórico de laudos e manuais técnicos da fábrica.

2. Módulo de Telemetria e Análise de Motores

A base da operação preditiva reside na captura contínua de dados de sensores acoplados aos ativos industriais.

- **Parâmetros Críticos:** O sistema foca primordialmente na leitura de Temperatura (em graus Celsius) e Frequência de Vibração (em Hz).
- **Limites de Tolerância:** Anomalias são detectadas quando a temperatura do estator ultrapassa 85°C contínuos ou quando a assinatura de vibração apresenta picos assimétricos superiores a 12 Hz, indicando possível desbalanceamento do rotor ou desgaste prematuro de rolamentos.

3. Pipeline de Inteligência Artificial e Processamento

O "cérebro" do sistema Predicta é alimentado por Modelos de Linguagem de Grande Escala (LLMs) executados através de uma infraestrutura robusta e otimizada.

Motor de Inferência: Utilizamos o modelo Llama 3 (desenvolvido pela Meta), operando 100% localmente através da engine Ollama.

Engenharia de Prompts

O diagnóstico não é feito de forma randômica. O sistema aplica técnicas de **Chain-of-Thought (CoT)** para forçar o LLM a raciocinar passo a passo sobre a telemetria antes de emitir um laudo. Adicionalmente, utiliza-se **Few-Shot Prompting** injetando exemplos de diagnósticos anteriores bem-sucedidos para calibrar a precisão da resposta da IA.

4. Estratégia de Indexação Vetorial (RAG)

Para que a inteligência artificial compreenda o contexto industrial de forma precisa, aplicamos uma rigorosa estratégia de vetorização de documentos.

- **Embeddings:** Os laudos técnicos e manuais são processados utilizando o modelo `all-MiniLM-L6-v2` da biblioteca Sentence Transformers, gerando vetores densos de 384 dimensões.
- **Chunking e Metadados:** Os textos longos são divididos (chunking) preservando a sobreposição de contexto. Cada vetor armazenado no Qdrant carrega metadados ricos, como a data de emissão do laudo, a máquina de origem e a gravidade do alerta.

5. Protocolos de Segurança e Privacidade

O isolamento de dados é uma prioridade absoluta na arquitetura da Predicta.

Inferência Offline: Como o ambiente industrial lida com dados sensíveis de produção, toda a geração de texto e cálculo de embeddings ocorre localmente ou na nuvem privada da operação. A ausência de chamadas a APIs externas (como a OpenAI) garante zero risco de vazamento de segredos industriais e elimina custos variáveis de faturamento por token.

CONFIDENCIAL - USO INTERNO

